


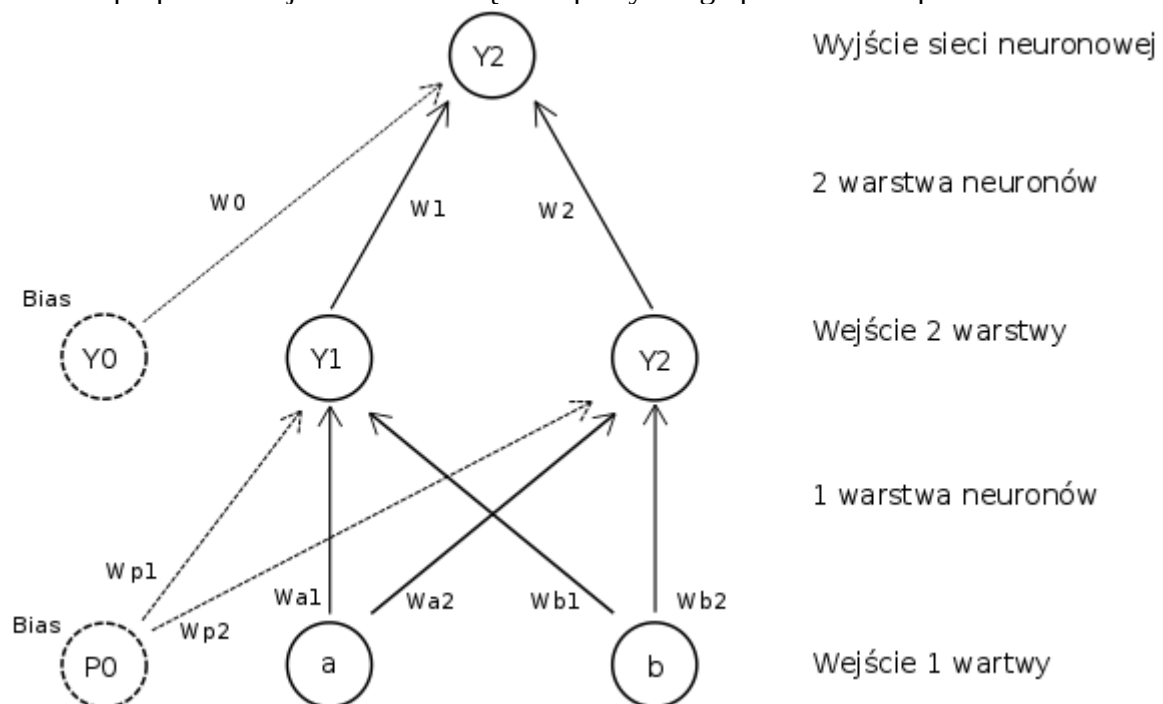
Celem projektu jest zaprojektowanie sieci neuronowej która była by w stanie przypisać punktom (a,b) wartości 1 lub 0 zgodnie z operacją logiczną alternatywa wykluczająca dalej w skrócie nazywaną XOR.

a	b	a XOR b
0	0	0
0	1	1
1	0	1
1	1	0



Jak widać na rysunku 1 nie jest możliwy podział płaszczyzny jedną linią tak by w jednej części znalazły się punkty o wartości 1 a w drugiej o wartości 0. W związku z tym proponowana sieć musi być przynajmniej dwu warstwowa.

Architektura proponowanej sieci do rozwiązania powyższego problemu ma postać:



Gdzie:

- a, b są wejściami sieci neuronowej i mogą przyjmować wartości 0 lub 1?
- Wa1, Wa2 ... są wagami odpowiadającym poszczególnym neuronom . Przed uczeniem wagi przyjmowały losową wartość od -1 do 1
- P0 i Y1 są biasem odpowiednio pierwszej i drugiej warstwy

Y1, Y2

są wyjściem pierwszej warstwy i jednocześnie wejściem dla warstwy 2 i wynoszą odpowiednio:

$Y_{01} = \frac{1}{1 - \exp(-\beta x_1)}$	gdzie	$x_1 = W_{p1} \cdot P_0 + W_{a1} \cdot a + W_{b1} \cdot b$
$Y_{02} = \frac{1}{1 - \exp(-\beta x_2)}$	gdzie	$x_2 = W_{p2} \cdot P_0 + W_{a2} \cdot a + W_{b2} \cdot b$
$Y = \frac{1}{1 - \exp(-\beta x)}$	gdzie	$x = W_0 \cdot Y_0 + W_1 \cdot Y_1 + W_2 \cdot Y_2$


Dane wejściowe do sieci mają następującą współrzędną:

[(1,0);(0,1);(1,1); (0,0)]

I odpowiadają wartości wyjściowe:

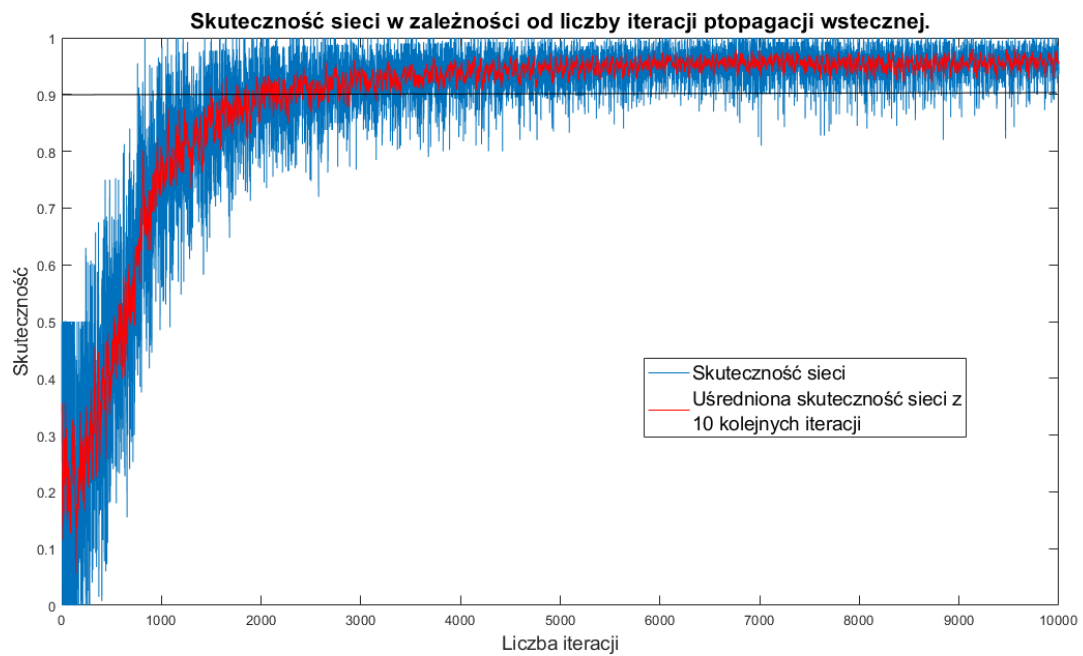
[1;1;0;0]

Dobór współczynnika uczenia i krzywizny.




Współczynnik krzywizny wstępnie przyjęto równy 1 natomiast współczynnik uczenia równy 6. Ze względu na dużą liczbę obliczeń, współczynnik uczenia i współczynnik krzywizny badane były przy liczbie iteracji wynoszącej 3000.

Liczbę iteracji propagacji wstecznej ustalono na 10000. Liczba ta jest na tyle duża, by skuteczność uczenia nie spadała poniżej 80% i na tyle mała, by obliczenia numeryczne nie stanowiły problemu dla komputera.




Funkcja aktywacji

Graph for $1/(1+\exp(-x))$



Pochodna funkcji aktywacji:

Graph for $1/(1+\exp(-x))*(1-1/(1+\exp(-x)))$




Podział na klasy sporządzono następujący:

0 dla wyjścia z sieci mniejszego niż 0.25


1 dla wyjścia z sieci większego niż 0.75

2 dla pozostałych wartości.


Podział przestrzeni na klasy wygląda następująco:



Ewentualnie



Po uśrednieniu 10 przypadków:



Jak poprawić skuteczność sieci:

1. Krosvalidacja: funkcji uczącej sieć dodać dane sprawdzające i wyznaczyć minimalną skuteczność jaką sieć może osiągnąć. Przy 10000 iteracjach propagacji wstecznej sytuacja taka powinna się zdarzyć nie częściej niż w 15%. Algorytm ten powinien zwiększyć skuteczność sieci w zadanych 4 punktach do 100% czasami zwiększając czas uczenia 2 krotnie.
2. Jeżeli nie chcemy zmieniać funkcji uczenia a chcemy zwiększyć skuteczność uczenia, możemy uśrednić wyjścia sieci uzyskane po około 10 różnych procesach uczenia. Pomysł drugi wydłużył by czas oczekiwania na wynik około 10 razy. Jak widać algorytm z uczeniem byłby skuteczniejszy.